

알람 예산 기반 자율주행 Fail-Safe 심각도 선별(스크리닝)을 위한 경량 FiGNN 모델 개발

김대근°, 송유재*

영남대학교 로봇공학과

22112369@yu.ac.kr, yjsong@yu.ac.kr

Development of a lightweight FiGNN model for autonomous driving fail-safe severity screening based on alarm budgets

Daekeun KIM and Yujae SONG*

Dept. of Robotics Engineering, Yeungnam University.

요 약

자율주행 안전을 위해 교통사고 심각도 예측이 필요하지만, 치명 사고(Severity 4, Sev4)는 매우 희귀하여 정확도(accuracy)가 높아도 Sev4를 놓치는 Accuracy Paradox가 발생한다. 본 연구는 경보율(alarm rate) 예산을 먼저 고정하고 그 안에서 Sev4 탐지 성능을 최대화 만드는 Budgeted Fail-Safe Screening을 제안한다. 경량 GNN인 FiGNN-Crash로 US Accidents를 엄격한 시간 순 분할로 평가한 결과[1], 경보율 32.5%에서 탐지 성능(Sev4 recall) 59.2%를 달성하며 RTX 3080 기준 0.835 ms/sample의 실시간성을 확인한다.

1. 서론

자율주행/첨단운전자보조시스템(ADAS)에서는 사고 발생 가능성뿐 아니라 사고가 발생했을 때의 심각도를 빠르게 추정하여 방어 행동을 촉발해야 한다. 그러나 실제 데이터에서 치명 사고(Sev4)는 극히 드물어 분류기가 다수 클래스를 예측하는 방향으로 수렴하며, 그 결과 정확도는 높아도 Sev4를 거의 탐지하지 못하는 Accuracy Paradox가 발생한다.[2] 이러한 상황에서 Macro-F1 등 단일 점수 최적화는 안전모드(Fail-Safe) 목적과 어긋나기 쉽다.[3] 또한 무작위 분할 평가는 시간 누수로 실사용 성능을 과대평가할 수 있으며, 합성 오버샘플링은 분포 왜곡 위험을 동반한다.[4] 따라서 본 연구는 “최고 성능 경쟁”이 아니라, 운영 제약을 먼저 고정하고 그 안에서 치명 사고를 최대한 잡는 Fail-Safe 스크리닝 문제로 재정의한다.

2. 본론

본 연구는 예산 기반 Fail-Safe 스크리닝(Budgeted Fail-Safe Screening)을 제안한다. 운영 정책은 위험 점수 상위 Top-k에만 개입을 발생시키는 방식으로

정의하며, 이때 k 는 경보율 예산을 의미한다(예: 32.5%). Neyman-Pearson(NP) 관점에서는 거짓 경보 비율을 예산으로 제한한 상태에서 탐지 성능을 최대화하는 운영점 선택이 정당화되며, 본 연구는 이를 장황한 이론 전개가 아닌 예산 기반 운영점 선택을 뒷받침하는 감사(audit)로만 사용한다. 즉 본 연구는 정확도 중심 단일 지표 최적화에서 벗어나, 경보율을 제어 변수로 고정한 뒤 Sev4 탐지성능을 핵심 목표로 삼는 설계를 채택한다.

모델은 FiGNN-Crash로 구성한다. FiGNN-Crash는 탭형 특징(feature) 필드를 노드로 간주하고 완전 그래프에서 자기주의(self-attention)으로 특징 상호작용(feature interaction)을 학습한다.[5] 연속형 특성은 선형 투영을 적용하고, 범주형 특성은 임베딩을 사용하여 동일 차원 표현을 구성한다. 이후 attention 기반 메시지 패싱으로 중요한 특징 조합을 강조하고, pooling과 경량 MLP를 통해 단일 위험 점수(risk score)를 출력한다. 이 구조는 약 20k 파라미터로 설계하여 Fail-Safe 감독기(supervisor)로 탑재 가능한 경량성을 확보한다. 또한 본 연구는 모델 정확도만이 아니라 추론 지연과 배포 가능성을 핵심 요구조건으로 함께 다룬다. 따라서 FiGNN-Crash는 약 20k 파라미터와 0.835 ms/sample의 실시간 추론 지연을

동시에 만족하여, 탑재 가능한 경량 Fail-Safe 감독기라는 설계 목표를 충족한다.

실험은 US Accidents 를 사용하여 수행하며, 실사용 배포에서의 동작을 모사하기 위해 엄격한 시간 순 분할(chronological split)과 임계값 동결(frozen policy) 평가를 적용한다. 그림 1 은 Train-Gap-Val-Test (학습-갭-검증-시험)의 시간 축 분할과, Val 에서 경보율 32.5%가 되도록 임계값을 보정한 뒤 이를 Test 에 그대로 적용하는 동결 정책을 나타낸다. 본 설정은 무작위 분할에서 발생할 수 있는 시간 누수와 과대평가를 방지하고, 현장 배포에서 동일하게 동작하는 평가 설계를 증명한다.[6]




그림 1. 시간 순 분할 및 임계값 동결 평가

그 결과 FiGNN-Crash 는 경보율 32.5%에서 Sev4 탐지성능 59.2%를 달성한다. 또한 RTX 3080, FP32, batch=1 에서 0.835 ms/sample 의 GPU 추론 지연을 확인하여 실시간 실행 가능성을 보인다. 더 나아가 본 연구는 단일 성능 수치만 제시하지 않고, 그림 2 에서 추론 지연(ms/sample)과 Sev4 탐지성능(경보율 32.5%)의 관계를 함께 제시하여 탑재성 트레이드오프를 시각화한다. 이때 FiGNN-Crash 는 높은 탐지성능과 낮은 지연, 작은 모델 크기를 동시에 만족하는 영역에 위치하도록 설계되며, 딥러닝 기반 Fail-Safe 감독기의 경량·실시간 구현이라는 본 연구의 목표를 직접적으로 뒷받침한다.




그림 2. 탑재성 트레이드오프

참고로 트리 앙상블(XGBoost)은 Sev4 탐지성능 69.3%로 상한 성능을 보이나, 본 연구는 최고 탐지성능 1 등이 아니라 현장 탑재가 가능한 경량 딥러닝 Fail-Safe 감독기를 구현하는 데 초점을 둔다.

그림 3 은 초기 경보가 반응시간을 단축시키면 총 제동거리가 감소하여 Δd 의 안전 마진(예: 약 30 m)을 확보함을 개념적으로 보인다.




그림 3. 초기 경보에 따른 제동거리 마진 개념도

본 연구는 이 마진 확보를 위한 트리거를 경보율 예산 기반 스크리닝으로 정의하며, FiGNN-Crash 가 경보율 32.5%에서 Sev4 탐지성능 59.2%를 달성하고 0.835 ms/sample 로 실시간 실행 가능성을 확인한다.

이 결과는 극단적 불균형 환경에서도 경보율 32.5% 예산 하에서 치명 사고를 의미 있게 탐지하면서, 실시간 탑재 제약을 동시에 만족함을 보여준다.

3.결론

본 연구는 Sev4 희귀성으로 인해 발생하는 Accuracy Paradox 를 운영 관점으로 재정의하고, 경보율 예산 하에서 탐지 성능을 최대화하는 Budgeted Fail-Safe Screening 을 제안한다. FiGNN-Crash 는 feature 상호작용을 그래프 attention 으로 학습하는 경량 GNN 으로서 약 20k 파라미터로 구현한다. US Accidents 의 시간 순 분할 평가에서 경보율 32.5%에서 탐지성능 59.2%를 달성하며, RTX 3080 에서 0.835 ms/sample 의 추론 지연을 확인하여 실시간 Fail-Safe 감독기로의 탑재 가능성을 보인다. 또한 초기 경보가 제동거리 마진을 확보한다는 물리적 직관을 제시하여, 예산 기반 스크리닝이 실질 안전 이득으로 연결됨을 설명한다.

참고문헌

- [1] M. Moosavi et al., "A Countrywide Traffic Accident Dataset," in *Proc. IEEE Intell. Transp. Syst. Conf. (ITSC)*, 2019..
- [2] H. He and E. A. Garcia, "Learning from Imbalanced Data," *IEEE TKDE*, 2009.
- [3] ISO 26262-1:2018, "Road vehicles — Functional safety — Part 1: Vocabulary," 2018.
- [4] N. V. Chawla et al., "SMOTE: Synthetic Minority Over-sampling Technique," *J. Artif. Intell. Res.*, 2002.
- [5] Z. Li et al., "FiGNN: Modeling Feature Interactions via Graph Neural Networks for Tabular Data," in *Proc. ACM Int. Conf. Inf. Knowl. Manage. (CIKM)*, 2019.
- [6] J. Gama et al., "A Survey on Concept Drift Adaptation," *ACM Computing Surveys*, 2014.